

Manual Operativo de Ejecución: Valoración Automática de Viviendas (Madrid)

Para: Equipo de Ciencia de Datos Espaciales

De: Consultoría Senior

Asunto: Protocolo de consolidación metodológica para el proyecto de valoración inmobiliaria.

1. Propósito y Objetivo

El éxito del proyecto se define por la construcción de un sistema de valoración automática (AVM) capaz de predecir el precio de la vivienda en Madrid, capturando la dependencia espacial inherente al mercado inmobiliario.

Se exige la implementación de dos enfoques técnicos diferenciados:

1. **Interpolación Geoestadística (Kriging).**
2. **Modelos de Machine Learning con componentes espaciales.**

Entregable final: Dos aplicaciones interactivas en **Shiny**.

2. Recomendaciones de Clase (Tips de Oro)

Basado en las notas de instrucción directa del profesor, se deben observar estrictamente las siguientes reglas de ejecución:

- **Gestión de Datos:** Muestreo con el **50% de los datos** para el entrenamiento debido al volumen (10,000 obs.).
- **Tratamiento de Valores Nulos:** Los valores perdidos en variables categóricas deben codificarse como "zzzz" (ej. para indicar que "no tiene" ese atributo).
- **Actualización de Precios:** Actualizar precios de 2010 a 2026 utilizando índices de mercado (ej. Idealista).
- **Variable Objetivo:** Modelizar el **logaritmo neperiano del precio** ($\log(\text{Price})$).
- **Estacionariedad:** El proceso debe ser estacionario. Eliminar tendencias mediante regresión antes de aplicar Kriging.
- **Simplicidad:** No se utilizarán semivariogramas direccionales (anisotropía).

3. Hoja de Ruta Técnica (Step-by-Step)

Fase I: Preparación de Datos Espaciales

Paso	Acción Técnica	Herramientas / Comandos	Fuente
1.1	Depuración y eliminación de outliers (Ver sección 5.1).	quantile, filter	[Tips]
1.2	Transformación logarítmica de la variable dependiente.	mutate(log_price = log(price))	[Cap. 8]
1.3	Tratamiento de categorías "zzzz" (Ver sección 5.4).	fct_na_value_to_level	[Tips]
1.4	Conversión a objeto espacial y proyección (EPSG: 25830).	st_as_sf(), st_transform	[Cap. 2]

Fase II: Análisis Exploratorio y de Dependencia

Paso	Acción Técnica	Herramientas / Comandos	Fuente
2.1	Cálculo de la I de Moran Global (autocorrelación).	moran.test()	[Cap. 6, 8]
2.2	Generación de Semivariograma Empírico.	gstat::variogram()	[Cap. 5]

Fase III: Modelización y Optimización

Paso	Acción Técnica	Herramientas / Comandos	Fuente
------	----------------	-------------------------	--------

3.1	Vía A (Geo): Ajuste de modelo teórico y Kriging.	fit.variogram, krige	[Cap. 5]
3.2	Vía B (ML): Inclusión de retardos espaciales (W_y).	spatialreg	[Cap. 7, 8]
3.3	Optimización manual de RF y XGBoost (Ver sección 5.2).	Manual Tuning	[Tips]
3.4	Selección de variables y descarte por p-valor (Sección 5.3).	Type 2 Analysis, AIC/BIC	[Tips]

4. Detección de Riesgos e Inconsistencias

1. **Modelos de Regresión vs. ML:** Se usará **Random Forest** como principal, pero con un modelo lineal espacial de base comparativa.
2. **Validación:** Se aplicará **Spatial Buffering** o **Block Cross-Validation** para evitar sobreestimación.
3. **Número de Apps:** Se desarrollarán **dos módulos independientes** (Kriging y ML) en Shiny.

5. Especificaciones Técnicas de Implementación

Este apartado contiene las instrucciones exactas y el código obligatorio para tareas críticas.

5.1 Protocolo de Eliminación de Outliers

La limpieza de la variable precio se realizará siguiendo el criterio del Rango Intercuartílico (IQR) con un factor de 3 para asegurar que solo se eliminen valores extremos atípicos:

Cálculo de límites estadísticos

```
stats <- quantile(df$house.price, probs = c(0.25, 0.75), na.rm = TRUE)
```

```
iqr_val <- diff(stats)
```

```
q_low <- stats[1] - 3 * iqr_val
```

```
q_high <- stats[2] + 3 * iqr_val
```

```
# Filtrado de la base de datos
df <- df |> filter(between(house.price, q_low, q_high))
```

5.2 Optimización de Modelos ML (RF y XGBoost)

Queda prohibido el uso de herramientas de auto-tuning automático. La optimización debe ser **manual**:

- **Procedimiento:** Iterar sobre parámetros clave (ej. `mtry`, `trees`, `learning_rate`) y evaluar manualmente el desempeño.
- **Comprobación:** Cada iteración debe registrar métricas tanto en el conjunto de **Train** como en el de **Test** para vigilar el sobreajuste (overfitting).
- **Guía de resultados:** Si el error en Test empieza a subir mientras el de Train baja, detener la complejidad del modelo.

5.3 Selección de Variables y Criterios de Calidad

Para la selección del set de variables final, se aplicarán los siguientes filtros estadísticos:

1. **Análisis de Tipo 2:** Realizar un análisis de la varianza (ANOVA) de Tipo II para evaluar la contribución marginal de cada variable.
2. **Criterios de Información:** Comparar modelos utilizando **AIC** (Akaike) y **BIC** (Bayesian). Se preferirá el modelo con los valores más bajos.
3. **Regla del P-valor:** Se deben eliminar aquellas variables cuya significación no sea clara.
 - Si $p\text{-valor} > 0.05$: La variable debe ser eliminada del modelo por falta de significación estadística.

5.4 Tratamiento de Categorías "zzzz"

La etiqueta "zzzz" debe interpretarse como la ausencia del atributo en variables categóricas, asegurando que el algoritmo no las trate como nulos (NA):

- **Ejemplo Variable Garaje:** Si el valor es "zzzz", se interpreta como "La vivienda no dispone de garaje".
- **Extensión:** Este criterio se aplica a todas las variables categóricas donde se detecte este patrón (ej. Trastero, Calefacción, etc.).